Computación Estadística con R

Alex Antequeda - Rubén Soza

Sesión 1

Programa del Curso

- Introducción a R.
- Instalación, entorno y estructura de datos.
- Lectura y Manipulación/Transformación de datos.
- Funciones y familia Apply.
- Visualización con ggplot2.
- Reportes (R Markdown).
- Extras dentro de cada clase.

Clases

- Cada clase tendrá una parte expositiva, ejercicios en conjunto y actividades.
- Si hay dudas, interrumpir. **No existen preguntas tontas!**.
- **Todos** escribiremos código.
- Todo el material estará en la página del curso.

Introducción a R

¿Por qué R?

- R es un lenguaje de programación para Computación Estadística.

¿ Existen programas similares, por qué usar R?

- R es **Gratis**.
- Existe una gran comunidad que lo utiliza.
- Puede manejar prácticamente cualquier formato de datos.
- Es un lenguaje, por lo que puede hacer todo.
- Es un buen trampolín para otros lenguajes como Python.

Descarga e Instalación

- R es el motor. (https://cran.r-project.org).
- RStudio es el panel de control. (https://rstudio.com).
- La instalación es como cualquier programa.
- Existe tambien https://rstudio.cloud.

Interfaz de RStudio

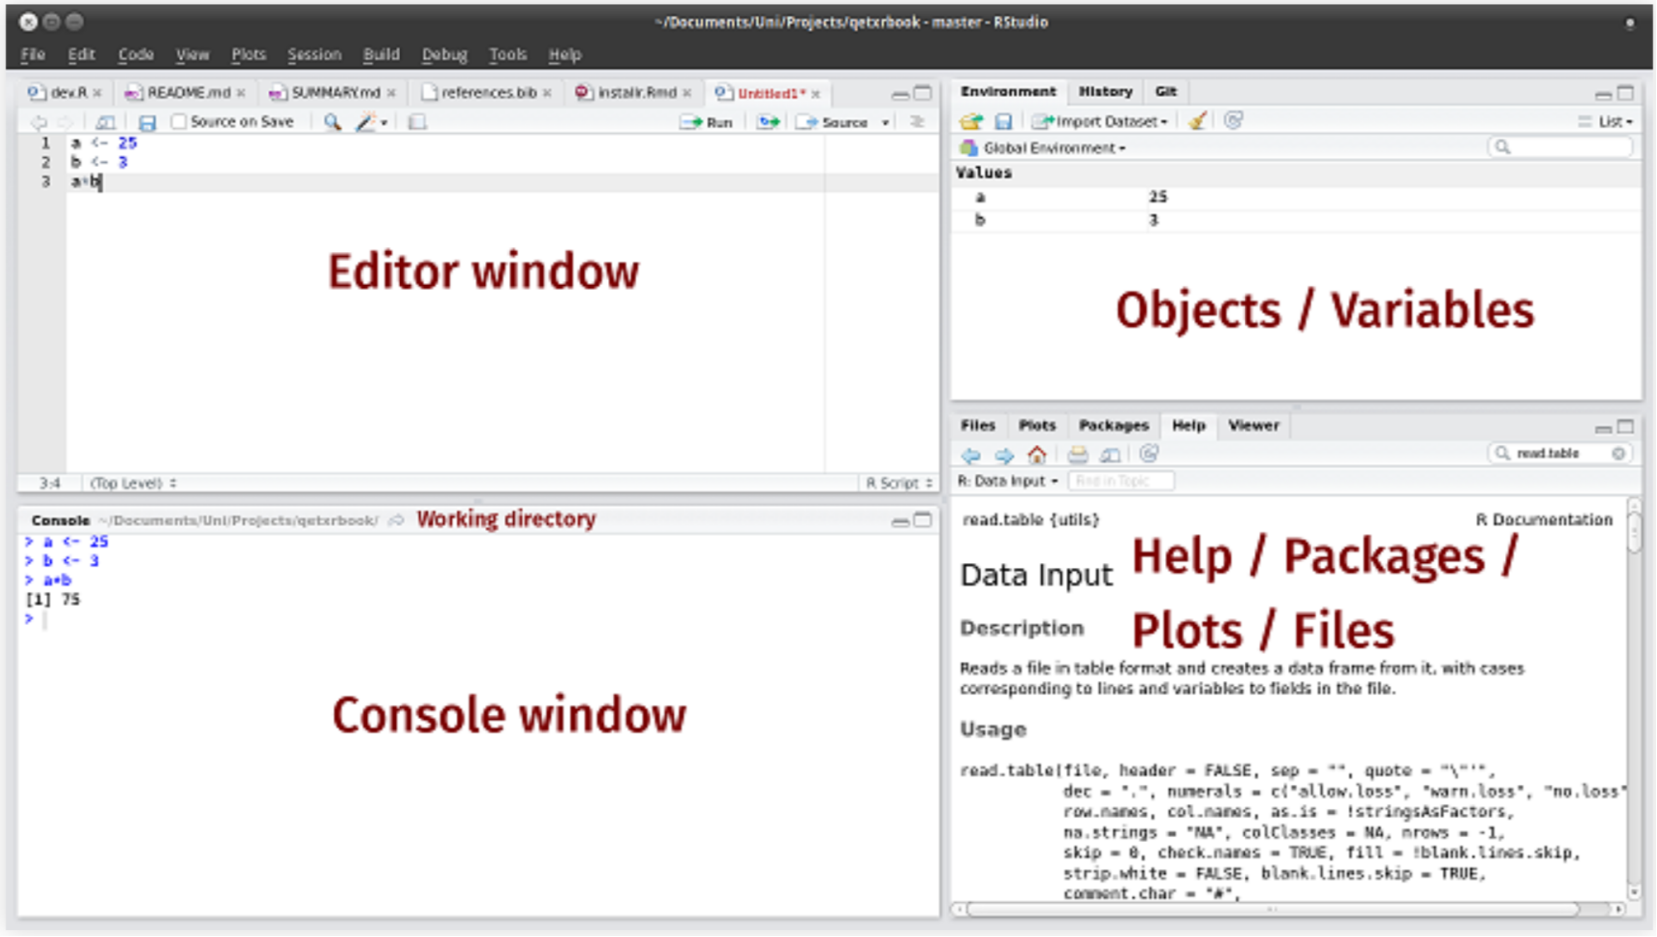

Estructura de Datos

Vectores

Los vectores los creamos con elementos del mismo tipo a través de la función **c( )** (concatenar). En caso de mezclar caracteres con datos numéricos, el vector se considerará caracter.

```
vec <- c(1,4,3.14,-2)  # <- es equivalente a usar =
vec
```

```
## [1]  1.00  4.00  3.14 -2.00
```

Dimensión/largo del vector

```
length(vec)
```

```
## [1] 4
```

Vectores (cont.)

Vectores reciclados

```
c(0.5,2) + c(1,2,3,4)
```

```
## [1] 1.5 4.0 3.5 6.0
```

```
c(0.5,2,0.5,2) + c(1,2,3,4)
```

```
## [1] 1.5 4.0 3.5 6.0
```

Vectores (cont.)

Un escalar es un caso especial

```
2 * c(1,-2,3) + 1
```

```
## [1]  3 -3  7
```

```
c(0.5,2) + c(4,-1,10)
```

```
## Warning in c(0.5, 2) + c(4, -1, 10): longer object length is
## not a multiple of shorter object length
```

```
## [1]  4.5  1.0 10.5
```

Obs: No reciclar para no tener sorpresas en los cálculos.

Matemática en vectores

Algunas funciones operan sobre todo un vector y no sobre cada elemento.

```
#Sobre cada elemento
c(1,2,3)^2
```

```
## [1] 1 4 9
```

```
# Sobre todo el vector
sum(c(3,2,6))
```

```
## [1] 11
```

Algunas otras funciones: **mean()**,**max()**, **min()**,**median()**, **sd()**, **var()**.

Ejemplo: Estandarizando datos

Supongamos que obtuvimos algunos valores de mediciones de ph y queriamos ponerlos en una escala estandarizada:

$$ph^* = \frac{x_i - mean(x)}{sd(x)}$$

```
ph <- c(1.1,3.0,4.2,0.7,7.1,8,5.6,13.3,12.0)
z <- (ph - mean(ph)) / sd(ph) # z = ph estandarizado
round(z, 2)                   # redondeamos a 2 decimales
```

```
## [1] -1.12 -0.70 -0.43 -1.21  0.22  0.42 -0.11  1.61  1.32
```

Ejercicio: Realizar la función **scale()** sobre el vector de datos y comparar.

Tipos de vectores

Las funciones **class()** o **str()** nos indican que tipo de vectores tenemos.

- **Numérico:** c(-2, 143, 1/2, -3.14) ,*Entero:* 0:10
- **caracter:** c("orange", "red", "yellow", "green")
- **factor:** factor(c("orange", "red", "yellow"))
- **lógico:** c(FALSE, FALSE, TRUE)

Generando vectores numéricos

```
seq(-2, 5, by = 1.75) # secuencia desde  -2 a 5, incrementos de 1.75
```

```
## [1] -2.00 -0.25  1.50  3.25  5.00
```

```
# seq(-2,5,length.out = 5) se obtiene lo mismo.
```

```
rep(c(-1, 0, 1), times = 3) # repetir c(-1,0,1) 3 veces
```

```
## [1] -1  0  1 -1  0  1 -1  0  1
```

```
rep(c(-1, 0, 1), each = 3) # repetir cada elemento 3 veces
```

```
## [1] -1 -1 -1  0  0  0  1  1  1
```

```
n <- 12
1:n
```

```
##  [1]  1  2  3  4  5  6  7  8  9 10 11 12
```

Generando vectores no numéricos

```r
# creamos un factor con tres niveles, a, b y c
mi.factor <- factor( sample( letters[1:3], 20, replace = T ) )
mi.factor
```

```
##  [1] a c c b a b c a a a b a a c c a c a a a
## Levels: a b c
```

```r
levels( mi.factor )    # a, b, c
```

```
## [1] "a" "b" "c"
```

```r
# preferimos la ordenación b, c, a

mi.factor <- factor( mi.factor,
                     levels = levels( mi.factor )[ c( 2,3,1 ) ] )
levels( mi.factor )     # b, c, a
```

```
## [1] "b" "c" "a"
```

Generando vectores lógicos

```
first_names <- c("Pedro", "Catalina", "Roberto","Andrea")
name_lengths <- nchar(first_names) # numero de caracteres
name_lengths
```

```
## [1] 5 8 7 6
```

```
name_lengths >= 4
```

```
## [1] TRUE TRUE TRUE TRUE
```

Obs: Se puede realizar calculos con vectores lógicos, porque, **TRUE**=1 y **FALSE**=0

Combinando condiciones lógicas

Si quisieramos solo los nombres con más de 6 letras:

```
largo <- name_lengths < 6
largo
```

```
## [1]  TRUE FALSE FALSE FALSE
```

Si quisieramos solo los nombres donde la cuanrta letra es "r":

```
# substr: substring (porción) de un char vector
letra.4 <- substr(first_names, start=4, stop=4) == "r"
letra.4
```

```
## [1]  TRUE FALSE FALSE  TRUE
```

Operadores lógicos

- **&** es "AND" (Ambas condiciones deben ser **TRUE**):

```
largo  & letra.4
```

```
## [1]  TRUE FALSE FALSE FALSE
```

- **|** es "OR" (Al menos una condicion debe ser **TRUE**):

```
largo  | letra.4
```

```
## [1]  TRUE FALSE FALSE  TRUE
```

Operadores lógicos (cont.)

- **!** es "NOT" (niega las propociones logicas, cambiando **TRUE** por **FALSE** y viceversa)

```
!largo
```

```
## [1] FALSE  TRUE  TRUE  TRUE
```

```
!(largo  & letra.4 )
```

```
## [1] FALSE  TRUE  TRUE  TRUE
```

Extra

```
# Obteniendo los nombres con largo mayor a 6
first_names[largo]
```

```
## [1] "Pedro"
```

```
# Si tenemos un vector con los sexos
sex <- c("M","F","M","F")
first_names[sex=="M"]        # para comparar usar doble signo = (==)
```

```
## [1] "Pedro"   "Roberto"
```

Extra (cont.)

```r
# Veamos si nuestra lista coincide en algun nombre con este vector
first_names %in% c("Roberto", "Carla", "Daniel")
```

```
## [1] FALSE FALSE  TRUE FALSE
```

```r
# Obtenemos la posición dentro de nuestro vector
which(first_names %in% c("Roberto", "Carla", "Daniel"))
```

```
## [1] 3
```

```r
# Veamos cual es el que coincide
first_names[3]
```

```
## [1] "Roberto"
```

NA's, Inf y NaN

Un valor perdido es codificado como **NA** sin "".

```
# un vector con valores NA
vector_conNA <- c(1,2,NA,4,-3,NA,NA,-4)
mean(vector_conNA)
```

```
## [1] NA
```

Problemas!... los NA no dejan hacer cálculos correctamente. que hacer? remover los valores uno por uno... que lata...

```
mean(vector_conNA, na.rm=TRUE)
```

```
## [1] 0
```

NA's, Inf y NaN (cont.)

```
# Para ver la posición de los valores NA
is.na(vector_conNA)
```

```
## [1] FALSE FALSE  TRUE FALSE FALSE  TRUE  TRUE FALSE
```

Como manejar los **NA**

```
vector_conNA == -3
```

```
## [1] FALSE FALSE    NA FALSE  TRUE    NA    NA FALSE
```

```
vector_conNA %in% -3
```

```
## [1] FALSE FALSE FALSE FALSE  TRUE FALSE FALSE FALSE
```

NA's, Inf y NaN (cont.)

```
vector_conNA %in% NA
```

```
## [1] FALSE FALSE  TRUE FALSE FALSE  TRUE  TRUE FALSE
```

```
# Como funcionan los Inf y NaN
vec <- c(-2, -1, 0, 1, 2) / 0 ; vec
```

```
## [1] -Inf -Inf  NaN  Inf  Inf
```

```
rbind(is.finite(vec),is.nan(vec))
```

```
##       [,1]  [,2]  [,3]  [,4]  [,5]
## [1,] FALSE FALSE FALSE FALSE FALSE
## [2,] FALSE FALSE  TRUE FALSE FALSE
```

Matrices

Una **Matriz** extiende los vectores a dos dimensiones. Veamos algunos comandos útiles

```
(a_matrix <- matrix(letters[1:8], nrow=2, ncol=4))
```

```
##      [,1] [,2] [,3] [,4]
## [1,] "a"  "c"  "e"  "g"
## [2,] "b"  "d"  "f"  "h"
```

```
(b_matrix <- matrix(letters[1:8], nrow=2, ncol=4, byrow=TRUE))
```

```
##      [,1] [,2] [,3] [,4]
## [1,] "a"  "b"  "c"  "d"
## [2,] "e"  "f"  "g"  "h"
```

Matrices (cont.)

```
# empalmando vectores por fila
(c_matrix <- rbind(c(2,4,6),c(-1,0,-3)))
```

```
##      [,1] [,2] [,3]
## [1,]    2    4    6
## [2,]   -1    0   -3
```

```
# empalmando vectores por columna
(c_matrix <- cbind(c(1, 2,5,3), c(3, 4), c(5, 6)))
```

```
##      [,1] [,2] [,3]
## [1,]    1    3    5
## [2,]    2    4    6
## [3,]    5    3    5
## [4,]    3    4    6
```

Aquí tenemos un problema...

Matrices (cont.)

```
##      [,1] [,2] [,3] [,4]
## [1,] "a"  "c"  "e"  "g"
## [2,] "b"  "d"  "f"  "h"
```

```
# extraer la fila 2
a_matrix[2,]
```

```
## [1] "b" "d" "f" "h"
```

```
# extraer la columna 3
a_matrix[2,]
```

```
## [1] "b" "d" "f" "h"
```

Matrices (cont.)

Ahora el comando para ver el tamaño es **dim()**

```
# primer valor es la cantidad de filas y el otro valor las columnas.
dim(a_matrix)
```

```
## [1] 2 4
```

```
matrix <- cbind(c("SI","NO"), c(18,31))
# nombramos las filas y columnas
rownames(matrix) <- c("Pedro", "Carla")
colnames(matrix) <- c("Fuma", "Edad")
matrix
```

```
##       Fuma Edad
## Pedro "SI" "18"
## Carla "NO" "31"
```

¿Algún problema?

```
 typeof(matrix)
```

```
## [1] "character"
```

Listas

Una **Lista** es un objecto que puede almacenar muchos tipos de datos

```
(mi.lista <- list("letras"      = letters[1:4],
                  "matriz"      = matrix(8:11, nrow = 2),
                  "resultados"  = lm(dist ~ speed, data = cars)))
```

```
## $letras
## [1] "a" "b" "c" "d"
##
## $matriz
##      [,1] [,2]
## [1,]    8   10
## [2,]    9   11
##
## $resultados
##
## Call:
## lm(formula = dist ~ speed, data = cars)
##
## Coefficients:
## (Intercept)        speed
##     -17.579        3.932
```

Listas (cont.)

Como acceder a cada conjunto de datos en una lista?

```
mi.lista[["letras"]]
```

```
## [1] "a" "b" "c" "d"
```

```
mi.lista$letras
```

```
## [1] "a" "b" "c" "d"
```

```
mi.lista[[1]]
```

```
## [1] "a" "b" "c" "d"
```

Renombrar elementos

Con el siguiente comando podemos renombrar tanto una columna o algún elemento de una lista.

```
require(reshape)

datos = rename(datos, c(nommbre_a_cambiar="newname"))
names (datos)
```

Vamos a RStudio

Actividad 1

Resolvamos los ejercicios propuestos con lo que hemos aprendido hasta el momento.

- Descargar el **script1_clase1.R**

Expresiones Regulares

Detectando Patrones

- **grep()** : encuentra las posiciones de las frases que contienen el patron.
- **grepl()**: valores lógicos del comando grep().
- **str_detect()**: idem a grepl().
- **strsplit() , str_split()**: dividen un string usando un patron.
- **str_locate() , str_locate_all()**: localiza el patron.
- **str_extract() , str_extract_all()**: Extraen las coincidencias (agregando simplify = T, se obtiene una matriz con los resultados.)
- **sub()** reemplaza las coincidencias (**gsub()** reemplaza todas.)
- **str_replace() , str_replace_all()**: idem a sub() y gsub().

Obs: todos los **str_** son cargando la libreria **stringr**.

Ejemplos

```
frases <- c("Chile se divide en regiones",
            "La región del Biobío esta en Chile",
            "El sur de chile es lo mejor")
patron <- '(en|Chile)'   # o "en|Chile"
```

```
grep(pattern = patron, frases)
```

```
## [1] 1 2
```

```
grep(pattern = patron, frases, value = T)
```

```
## [1] "Chile se divide en regiones"
## [2] "La región del Biobío esta en Chile"
```

Ejemplos (cont.)

```
grepl(pattern = patron, frases)
```

```
## [1]  TRUE  TRUE FALSE
```

```
strsplit(frases, patron)
```

```
## [[1]]
## [1] ""            " se divide " " regiones"
##
## [[2]]
## [1] "La región del Biobío esta " " "
##
## [[3]]
## [1] "El sur de chile es lo mejor"
```

Ejemplos (cont.)

```
stringr::str_locate_all(frases , patron)
```

```
## [[1]]
##      start end
## [1,]     1   5
## [2,]    17  18
##
## [[2]]
##      start end
## [1,]    27  28
## [2,]    30  34
##
## [[3]]
##      start end
```

Ejemplos (cont.)

```
stringr::str_extract_all(frases , patron)
```

```
## [[1]]
## [1] "Chile" "en"
##
## [[2]]
## [1] "en"    "Chile"
##
## [[3]]
## character(0)
```

```
stringr::str_extract_all(frases , patron, simplify = T)
```

```
##      [,1]    [,2]
## [1,] "Chile" "en"
## [2,] "en"    "Chile"
## [3,] ""      ""
```

Extra. paste()

Realize un vector que diga "iter 1", "iter 2",..., "iter 5".

```
iteraciones <- c("iter 1","iter 2","iter 3","iter 4","iter 5")
iteraciones
```

```
## [1] "iter 1" "iter 2" "iter 3" "iter 4" "iter 5"
```

Fácil!... pero si necesitamos que sea un vector de la forma "iter 1",..., "iter 1.000"

```
iteraciones <- paste("iter",sep= " ",1:1000)
sample(iteraciones,10)
```

```
##  [1] "iter 415" "iter 915" "iter 557" "iter 296" "iter 781"
##  [6] "iter 860" "iter 456" "iter 647" "iter 969" "iter 422"
```

Extra.

- **merge()**: Para concatenar 2 bases de datos. (lo veremos más adelante(algo similar) con dplyr)
- **aggregate()**: agrega una base de datos. su comportamiento es en fórmula **X ~ Y**, Si X es una variable númerica e Y una de categorías voy a encontrar una función de X para cada categoría de Y. Entrega un nuevo objeto que es un dataframe.
- **subset()**: realiza filtro (similar a **[ ]**). Le entrego un objeto y le digo que sustraer. Reduce la dimensión del objeto a los que cumplen la condición. Retorna el mismo objeto filtrado.

Vamos a RStudio

Actividad 2

Resolvamos los ejercicios propuestos con la ayuda de las expresiones regulares.

- Descargar la base de datos **Encuesta.xlsx**
- Descargar el **script2_clase1.R**